

BASIRA — Note de synthèse

Défi principal **T20 — Risk scoring dynamique de la conformité des entreprises** · défi complémentaire T7 (croisement des données fiscales, douanières et de paiement). Hackathon « IA & Finances publiques », septembre 2026.

1. Problème traité

Les informations utiles au contrôle existent déjà mais restent en silos : déclarations fiscales, douane (SINDA), paiements publics (ADEB), annexes de l'employeur. La sélection des contrôles repose sur des règles statiques qui favorisent les grandes entreprises et les secteurs « classiques », pour une couverture de l'ordre de 2,5 % des contribuables. **Basira** classe chaque mois tout le portefeuille par **risque × enjeu**, explique chaque score par des faits chiffrés et les pièces sources, et laisse la décision à l'inspecteur : aucune sanction n'est automatique.

2. Données utilisées

Données **entièrement synthétiques** (aucune donnée réelle) : 5 250 entreprises sur 24 mois (2024-09 → 2026-08), au format du dossier fiscal, de la déclaration mensuelle, des annexes I, II et V, des déclarations et liquidations douanières, des paiements ADEB et des contrôles passés. Le générateur injecte 7 schémas de fraude (minoration du CA, réseaux de fausses factures, sous-évaluation en douane, recettes publiques non déclarées, dormante réactivée, compression de marge, sociétés coquilles) et des témoins trompeurs (croissance légitime, citoyens modèles, sosies sans fraude). La vérité terrain n'est lue que par l'évaluation, jamais par l'entraînement ni pour fixer un seuil. Un calcul à fin M ne lit que ce qui était disponible à cette date (déclaration de M connue en M+1, annexes de l'exercice N en mars N+1).

3. Approche IA

- **16 signaux explicables**, 4 lentilles : *cohérence* entre sources indépendantes (imports ou paiements reçus vs CA déclaré, TVA import, prix de référence en douane), *changement* (EWMA sur l'historique propre), *pairs* (écart robuste médiane/MAD, distance de Mahalanobis régularisée par secteur × taille), *réseau* (fournisseurs partagés, coquilles, proximité d'entreprises redressées). Statistiques déterministes ; chaque signal actif porte un fait en français et jusqu'à 50 pièces sources.
- **Score appris** : régression logistique L2 sur 276 contrôles passés (87 redressements), caractéristiques au mois précédant l'avis, poids ≥ 0 (un signal d'alerte ne baisse jamais le risque). Les signaux jamais observés en contrôle ou à coefficient négatif — effet du biais de sélection de la règle statique — reçoivent un poids a priori (médiane des poids appris). Échelle fixée par la capacité de contrôle (1 % des couples entreprise × mois ≥ 70) ; un écart très marqué entre deux sources indépendantes suffit à rendre l'entreprise prioritaire ; plafond 99. Chaque point est attribué à un signal (somme des points = score – score de base) : l'explication est exacte par construction.
- **Priorité** = score × enjeu (droits éludés reconstitués à partir des écarts entre sources). Segments PRIORITAIRE, SURVEILLANCE, NORMAL et CONFIANCE (voie de facilitation) ; action suggérée (demande d'information, vérification, signalement à la douane).
- **Assistant** : Qwen 3.5 9B hébergé en local, 4 outils (dossier, preuves, réseau, lettre de demande d'information). Tout chiffre de la réponse doit provenir des outils, sinon Basira renvoie une réponse déterministe ; l'assistant ne décide jamais.
- **Prototype** : application web de l'inspecteur (liste priorisée, fiche « Pourquoi ce score ? » avec pièces sources, graphe du réseau déployable de proche en proche, copilote, décision motivée et journalisée). Les décisions deviennent de nouveaux exemples étiquetés : **boucle d'apprentissage** (simulation avant/après sur 30 décisions, sans réentraînement en direct).

4. Résultats (données synthétiques)

Chaque mois de la période de test (2025-09 → 2026-08), chaque méthode choisit 50 entreprises à contrôler. Moyennes mensuelles :

Méthode	Fraudes dans la sélection	Droits éludés / contrôle	Croissances légitimes retenues
Basira	87 %	1 512 869 DT	3,2
Règle statique (type SAR)	23 %	483 982 DT	18,1
Sélection aléatoire	5 %	30 873 DT	1,0

En 2026-08, 208 entreprises sont PRIORITAIRE, dont **73 % de fraudes actives**. Robustesse : un modèle entraîné uniquement sur les 164 contrôles antérieurs à la période de test garde 87 % de fraudes dans sa sélection.

5. Limites identifiées

- Les données et les signaux sont conçus à partir de la même spécification : ces résultats montrent la faisabilité et l'intérêt du croisement des sources, pas l'efficacité en production.
- Avec 276 contrôles passés, rares, bruités et biaisés par leur sélection, les poids appris ne font pas mieux que des poids égaux (AUC en validation croisée 0,626 contre 0,618 ; sélection 87 % contre 88 %). La performance vient du croisement des sources ; l'apprentissage prendra son sens avec les décisions des inspecteurs.
- Pas d'avance de détection mesurée sur la règle statique (0,1 mois) ; une fraude entre dans la sélection 4,5 mois après son début en moyenne, et 86 fraudes sur 299 y entrent au moins une fois.
- Schémas mal couverts : dormante réactivée (12 % PRIORITAIRE), compression de marge (8 %) ; 9 % des croissances légitimes sont PRIORITAIRE.
- L'enjeu est une estimation (données annuelles, double compte possible clients/ADEB, taux de prototype à valider). Le référentiel d'activités n'est pas unifié entre administrations ; SAR et SADEC 2 ne sont connus que par la conférence.

6. Modèles, bibliothèques et API tierces

- C — Régression logistique L2 à poids non négatifs (scikit-learn), 16 signaux + 2 combinaisons ; pré-entraîné : non ; entraînée sur les contrôles passés synthétiques (data/scores/modele.json).
- C — Qwen 3.5 9B (poids ouverts) ; pré-entraîné : oui ; assistant de l'inspecteur, sans réentraînement ; servi en local par llama.cpp (llama-server, API compatible OpenAI) sur un PC du réseau local, aucune donnée ne sort.
- A — Qwen (local, via llama-server) ; pré-entraîné : oui ; étape hors ligne facultative : vocabulaire des noms d'entreprises fictives (generation/vocab/llm_vocab.json) ; la génération des données n'appelle pas le modèle.

A (données synthétiques) : numpy, pandas, networkx, vis-network (explorateur du graphe hors ligne) · B (signaux) : numpy, pandas, pyarrow, reportlab · C (score, API, assistant) : scikit-learn, FastAPI, Uvicorn, Pydantic, client openai (API compatible OpenAI) · D (interface) : React 19, Vite, Mantine, Tailwind CSS, React Flow (@xyflow/react), dagre, dc.js, Crossfilter, D3, react-markdown, lucide-react, React Bits (animation LatticeLoader), polices IBM Plex Mono et Public Sans. Aucune API externe ni service en ligne : tout fonctionne hors connexion.

7. Recommandations pour une mise en production

Brancher les sources au data lake SADEC 2 et à SINDA en conservant les dates de disponibilité ; unifier identifiants et référentiel d'activités ; valider les signaux et l'enjeu avec les métiers. Héberger données et assistant dans le périmètre de l'administration, avec habilitations, journalisation, minimisation et examen loi 2004-63 / INPDP. Réentraîner sur les résultats réels et les décisions des inspecteurs, suivre les biais par secteur, taille et région, et garder la décision humaine.