

BASIRA — Note de synthèse

Défi principal **T20 : score de risque dynamique de la conformité des entreprises**. Défi complémentaire T7 : croisement des données fiscales, douanières et financières. Hackathon « IA & Finances publiques », septembre 2026.
Code source : <https://github.com/Karim-zitouna-01/basira>

1. Le défi

L'administration dispose déjà de nombreuses informations sur les entreprises, mais elles sont réparties entre plusieurs systèmes : les déclarations fiscales, la douane (SINDA), les paiements de l'État aux entreprises (ADEB) et les annexes de l'employeur, où chaque entreprise déclare ce qu'elle a payé à ses fournisseurs. Les contrôles sont aujourd'hui choisis par des règles fixes, qui visent surtout les grandes entreprises. Or la fraude se voit souvent en comparant ces sources entre elles. Par exemple, une entreprise qui importe trois fois plus sans que son chiffre d'affaires déclaré augmente.

Basira attribue chaque mois à chaque entreprise un **score de risque de 0 à 100**, estime le montant d'impôt en jeu et propose la liste des entreprises à contrôler en priorité. Chaque score est expliqué par des faits chiffrés et par les pièces qui les prouvent. L'inspecteur garde toujours la décision.

2. Les données

Aucune donnée réelle n'a été fournie ni utilisée. Nous avons généré des données fictives réalistes, au format des documents officiels : **5 250 entreprises suivies sur 24 mois** (septembre 2024 à août 2026), avec leurs déclarations fiscales, leurs importations, les paiements publics reçus, ce que leurs clients déclarent leur avoir payé, et les résultats de 276 contrôles passés. Nous y avons caché 7 types de fraude connus (chiffre d'affaires minoré, fausses factures, sous-évaluation en douane, sociétés écrans...), ainsi que des entreprises honnêtes au comportement trompeur, comme une forte croissance correctement déclarée. La liste des vraies fraudes reste cachée. Elle sert uniquement à mesurer les résultats, jamais à entraîner le modèle. Chaque calcul n'utilise que les informations disponibles à la date concernée.

Conformité (loi organique n° 2004-63, INPDP). Aucune donnée personnelle ou confidentielle n'est utilisée, et aucun système de l'administration n'est sollicité. Les identifiants, les noms et les montants sont fictifs. Les données et l'assistant restent sur le réseau local, et rien n'est envoyé à un service en ligne.

3. L'approche IA, en trois étapes

- **Détecter**. Basira calcule 16 indicateurs d'alerte pour chaque entreprise et chaque mois. Ils comparent ce que l'entreprise déclare avec ce que les autres administrations observent, avec son propre passé et avec les entreprises du même secteur et de même taille. D'autres repèrent les liens suspects entre entreprises, comme des fournisseurs communs apparus en même temps ou des sociétés écrans. Chaque alerte est accompagnée d'une phrase explicative et des pièces qui la justifient.
- **Évaluer le risque**. Un modèle d'apprentissage automatique (régression logistique) apprend, à partir des 276 contrôles passés, l'importance de chaque indicateur. Il produit un score de 0 à 100 que l'on peut décomposer : chaque point du score est rattaché à un indicateur précis. On sait donc toujours pourquoi une entreprise est jugée risquée. Le score est ensuite combiné au montant estimé en jeu pour classer les entreprises à contrôler.
- **Assister l'inspecteur**. Un assistant conversationnel, le modèle de langage Qwen installé en local, répond aux questions de l'inspecteur à partir des seules données du dossier. Il peut par exemple remonter une chaîne de fournisseurs jusqu'à une entreprise déjà sanctionnée et l'afficher en direct sur le graphe des relations, ou rédiger une demande d'information. Si une réponse contient un chiffre absent des données, elle est bloquée et remplacée par une réponse préparée à l'avance. L'assistant ne prend aucune décision.

Le prototype est une application web : liste des entreprises classées par priorité, fiche de chaque entreprise avec l'explication de son score et les pièces, graphe de ses relations, assistant et formulaire de décision motivée. Les décisions des inspecteurs deviennent de nouveaux exemples pour réentraîner le modèle, ce que nous avons simulé sur 30 décisions.

4. Les résultats

Comment nous avons mesuré. Nous avons rejoué une année de contrôles, de septembre 2025 à août 2026. Chaque mois, trois méthodes choisissent chacune **50 entreprises à contrôler** parmi les 5 250, ce qui correspond à une capacité de contrôle réaliste : Basira, une règle fixe proche des pratiques actuelles (elle privilégie les grandes entreprises et quelques indicateurs classiques), et un tirage au hasard. On compare ensuite leurs choix à la liste cachée des vraies fraudes. Les chiffres sont des moyennes sur les 12 mois.

Méthode de sélection	Part des entreprises choisies qui fraudent réellement	Montant éludé retrouvé en moyenne par contrôle	Entreprises honnêtes en forte croissance choisies à tort, par mois
Basira	87 %	1,5 million de DT	3,2
Règle fixe, proche des pratiques actuelles	23 %	483 982 DT	18,1
Tirage au hasard	5 %	30 873 DT	1,0

Lecture. Sur les 50 entreprises proposées chaque mois par Basira, 43,5 en moyenne fraudent réellement (87 %), contre 11,6 avec la règle fixe et 2,5 avec un tirage au hasard. Chaque contrôle proposé par Basira porte en moyenne sur 1,5 million de DT d'impôt éludé, soit 3 fois plus qu'avec la règle fixe. Basira écarte aussi beaucoup mieux les entreprises honnêtes en forte croissance (3,2 par mois contre 18,1).

En août 2026, 208 entreprises sur 5 250 sont classées prioritaires, et 73 % d'entre elles fraudent réellement. Le résultat ne dépend pas des contrôles utilisés pour l'apprentissage : un modèle entraîné uniquement sur les contrôles antérieurs à l'année de test obtient le même taux (87 %).

5. Les limites

- Les données sont fictives et ont été conçues en même temps que les indicateurs. Les résultats montrent que l'approche fonctionne et que le croisement des sources est utile, mais pas son efficacité sur des données réelles.
- Avec seulement 276 contrôles passés, le modèle appris ne fait pas mieux qu'une simple moyenne des indicateurs (87 % contre 88 %). Le gain vient surtout du croisement des sources. L'apprentissage deviendra utile avec les décisions des inspecteurs.
- Basira ne repère pas les fraudes plus tôt que la règle fixe. Une fraude est proposée au contrôle 4,5 mois après son début, en moyenne.
- Deux types de fraude sont mal détectés : l'entreprise dormante qui reprend soudain une activité (12 % classées prioritaires) et la marge qui se réduit progressivement (8 %). Par ailleurs, 9 % des entreprises honnêtes en forte croissance sont classées prioritaires à tort.
- Le montant en jeu est une estimation, fondée en partie sur des données annuelles, et ses taux doivent être validés avec les inspecteurs.

6. Modèles, bibliothèques et ressources utilisés

Élément	Rôle dans Basira	Nature
Qwen 3.5 9B (Alibaba, poids ouverts, version compressée Q4_K_M)	Assistant de l'inspecteur. Sert aussi, une seule fois et hors ligne, à proposer des noms d'entreprises fictives.	Modèle pré-entraîné, utilisé sans réentraînement
llama.cpp (serveur llama-server, lancé via l'application Locally Uncensored)	Fait tourner Qwen sur un ordinateur du réseau local de l'équipe.	Serveur de modèle
Régression logistique (scikit-learn 1.9)	Calcule le score de risque à partir des 16 indicateurs.	Modèle entraîné par l'équipe
Python 3.13 : numpy, pandas, pyarrow, networkx	Génération des données, calcul des indicateurs, graphe des relations.	Bibliothèques
FastAPI, Uvicorn, Pydantic, client openai	Serveur de l'application et dialogue avec Qwen.	Bibliothèques
React 19, Vite, Mantine, Tailwind CSS, React Flow, dagre, dc.js, D3	Interface web, graphiques et graphe des relations.	Bibliothèques
React Bits (animation LatticeLoader), vis-network, polices IBM Plex Mono et Public Sans	Animation d'attente du copilote, explorateur du graphe, typographie.	Code et ressources externes repris et cités

Aucune API externe ni aucun service en ligne n'est utilisé : tout fonctionne hors connexion. Versions exactes dans les fichiers uv.lock et web/package-lock.json du dépôt.

7. Recommandations pour une mise en production

Relier Basira aux systèmes réels, notamment le lac de données SADEC 2 et SINDA, en conservant la date à laquelle chaque information devient disponible. Unifier les identifiants et le référentiel des activités entre administrations. Valider les indicateurs et l'estimation des montants avec les inspecteurs. Héberger les données et l'assistant au sein de l'administration, avec une gestion des droits d'accès et la traçabilité des consultations. Avant tout usage de données réelles, réaliser une analyse d'impact et accomplir les formalités auprès de l'INPDP (loi organique n° 2004-63). Enfin, réentraîner régulièrement le modèle avec les résultats réels des contrôles, surveiller les écarts de traitement selon le secteur, la taille et la région, et garder la décision humaine.